



(12) 发明专利申请

(10) 申请公布号 CN 114722727 A

(43) 申请公布日 2022.07.08

(21) 申请号 202210516706.8

(22) 申请日 2022.05.13

(71) 申请人 深圳市第二人民医院(深圳市转化
医学研究院)

地址 518035 广东省深圳市福田区笋岗西
路3002

(72) 发明人 王莹

(51) Int.Cl.

G06F 30/27(2020.01)

G06F 119/02(2020.01)


权利要求书3页 说明书5页 附图4页

(54) 发明名称

一种基于机器学习的太赫兹物质识别方法
及装置

(57) 摘要

本申请涉及基于机器学习的太赫兹物质识别方法及装置。所述方法包括:获取太赫兹光谱数据,将太赫兹光谱数据分别存入对应数据库,对太赫兹光谱数据做预处理,对预处理后的数据实施特征工程,以实施特征工程后的数据为机器学习数据源训练预测模型,通过预测模型预测物质成分,根据预测结果优化预测模型。采用本方法提高了物质识别的效率和识别结果的有效利用。



1. 一种基于机器学习的太赫兹物质识别方法,其特征在于,所述方法包括:
获取太赫兹光谱数据;
太赫兹光谱数据存入数据库;
数据预处理;
实施特征工程;
机器学习训练预测模型;
预测物质成分;
优化预测模型。
2. 根据权利要求1所述的一种基于机器学习的太赫兹物质识别方法,其特征在于,所述获取太赫兹光谱数据包括:
S10101,获取已知物质成分的太赫兹频域光谱图像;
S10102,获取已知物质成分的太赫兹光谱描述数据;
S10103,获取已知物质成分的太赫兹检测数据;
S10104,获取未知物质成分的太赫兹频域光谱图像;
S10105,获取未知物质成分的太赫兹光谱描述数据;
S10106,获取未知物质成分的太赫兹检测数据。
3. 根据权利要求1所述的一种基于机器学习的太赫兹物质识别方法,其特征在于,太赫兹光谱数据存入数据库:
S10201,选择太赫兹光谱图像;
S10202,确定太赫兹图像唯一编码;
S10203,太赫兹光谱图像存入图像数据库,如对象存储、图数据库或存储图像位置信息等方式;
S10204,选择太赫兹光谱对应描述数据
S10205,太赫兹描述数据存入关系型数据库或Nosql数据库;
S10206,选择太赫兹检测数据;
S10207,确定太赫兹检测数据对应唯一编码;
S10208,太赫兹检测数据存入关系型数据库或NoSql数据库。
4. 根据权利要求1所述的一种基于机器学习的太赫兹物质识别方法,其特征在于,所述数据预处理包括:
S10301,选择太赫兹频域光谱图像;
S10302,太赫兹频域光谱图像去噪;
S10303,太赫兹频域光谱图像倾斜校正;
S10304,判断是否需要太赫兹频域光谱图像二值化;
S10305,太赫兹频域光谱图像二值化;
S10306,太赫兹频域光谱图像取样;
S10307,太赫兹频域光谱图像量化;
S10308,太赫兹频域光谱图像矩阵化表示;
S10309,太赫兹频域光谱图像转为一维数组或数据库中一条记录;
S10310,判断是否需要对太赫兹图像描述数据转换;

S10311,根据预设规则把太赫兹图像描述数据通过傅立叶变换或小波变换等方法转换为统一的量纲;

S10312,判断是否需要对太赫兹检测数据转换;

S10313,根据预设规则把太赫兹检测数据通过傅立叶变换或小波变换等方法转换为统一的量纲,例如把太赫兹检测数据的电场数据转化为频域数据;

S10314,太赫兹时域光谱图像;

S10315,太赫兹时域光谱图像去噪;

S10316,太赫兹时域光谱图像取样;

S10317,太赫兹时域光谱图像量化;

S10318,太赫兹时域光谱图像矩阵化表示;

S10319,太赫兹时域光谱图像转为一维数组或数据库中一条记录;

S10320,按照预设规则把时域光谱图像的一维数据通过傅立叶变换或小波变换等方法转化为统一的量纲。

5.根据权利要求1所述的一种基于机器学习的太赫兹物质识别方法,其特征在于,所述特征工程包括:

S10401,选择全部或部分预处理后的数据作为特征列;

S10402,选择物质成分为目标列;

S10403,若采用二分类机器学习算法则某已知物质成分数值设为“1”,其他已知物质成分设为“0”;

S10404,若采用多分类机器学习算法则按照物质成分分别做数字编号;

S10405,若采用聚类机器学习算法则无需选择目标列;

S10406,对特征列数值做数据结构转换,例如转为大数据宽表形式;

S10407,对特征列数值做数据类型转化,例如统一转为Double类型;

S10408,对特征列数值做归一化处理,把数值压缩到[0,1]区间,去除量纲影响,加快收敛速度。

6.根据权利要求1所述的一种基于机器学习的太赫兹物质识别方法,其特征在于,所述机器学习训练预测模型包括:

S10501,若存在一定量的特征值对应的为已知物质成分;

S10502,采用分类机器学习算法(如逻辑回归、支持向量机、随机森林、K近邻等)基于训练数据生成预测模型;

S10503,采用预测模型对测试数据预测,生成预测结果;

S10504,采用混淆矩阵或分类评估算法对预测结果评估;

S10505,若具备分类能力(预测结果概率大于0.5),则预测模型可用;

S10506,对未知物质成分的光谱数据采用预测模型预测;

S10507,若预测结果符合预设规则(如概率大于0.8),则未知物质成分属于训练数据中某已知物质成分类别;

S10508,若预测结果低于预设规则(如概率小于0.5),则未知物质成分不属于训练数据中所有物质成分中的一种;

S10509,采用聚类机器学习算法(如K-Means、DBSCAN等)对物质的光谱数据进行计算;

S10510,根据聚类情况判断物质的归属类别;

S10511,若分类或聚类算法均无法对未知物质成分进行识别;

S10512,则该物质成分为数据库中不存在的类别;

S10513,通过其他手段识别该物质成分,得出识别结果;

S10514,根据所述识别结果,在数据库中修改、补充相应信息。

7.一种基于机器学习的太赫兹物质识别装置,其特征在于,所述装置包括:

获取模块,用于获取太赫兹光谱数据;

存储模块,存储太赫兹光谱数据、机器学习相关数据;

数据处理模块,太赫兹光谱图像做图像去噪、图像倾斜校正、图像二值化、图像采样和图像量化,对太赫兹光谱数据采用小波变化、傅里叶变换等做数据转换,对光谱信息和测量相关数据(如检测物质相关信息、时间、温度和湿度等)机器学习的数据结构转换、数据类型转换、数据归一化、数据拆分为训练数据和测试数据;

机器学习训练模块,采用机器学习算法基于训练数据生成预测模型;

机器学习预测模块,采用预测模型对测试数据或待预测物质的太赫兹光谱数据进行预测;

机器学习评估模块,采用混淆矩阵或分类评估方法根据机器学习预测模型对测试数据的预测结果评估其预测水平;

统计分析模块,统计分析数据库中各类数据;

数据展示模块,提供数据展示功能,采用报表、投屏等方式展示数据。

一种基于机器学习的太赫兹物质识别方法及装置

技术领域

[0001] 本发明属于数据处理领域,涉及到一种基于机器学习的太赫兹物质识别方法及装置。

背景技术

[0002] 太赫兹(Tera Hertz,THz)是波动频率单位之一,太赫兹泛指频率在0.1~10太赫兹波段内的电磁波,处于宏观经典理论向微观量子理论、电子学向光子学的过渡区域。频率上它要高于微波,低于红外线;能量大小则在电子和光子之间。由于此交叉过渡区,既不完全适合用光学理论来处理,也不完全适合用微波的理论来研究。

[0003] 数据库技术是现代计算机技术的一个重要组成部分,是处理数据的有效工具。数据挖掘是挖掘信息,发现知识,没有明确的假设,即没有事先的研究和设计,获得的信息应该具有三个特征:以前未知的,有效的和实用的。数据挖掘方法可分为两类:描述性和预测性。描述性模式表征数据的一般性质,包括关联分析和聚类分析。预测模式根据当前数据进行汇总,包括分类和回归。机器学习(Machine Learning,ML)具有处理非线性数据的能力,可以从现有数据中学习后找到新的模式并生成预测。

[0004] 目前,太赫兹检测侧重于物质识别与成像,对太赫兹光谱数据库建设的重视不足。而且光谱数据的采集侧重关键点,例如吸收峰、折射率等,对于其他光谱数据基本弃之不用。其所蕴含的信息随之灭失。通过人工观察太赫兹光谱曲线中的吸收峰、谷、肩峰等曲线特征来识别物质成分或采集相关图像中数据,存在效率低和人为误差的问题。

发明内容

[0005] 基于此,有必要针对上述技术问题,提供一种能够提高数据处理效率和数据挖掘的基于机器学习的太赫兹物质识别方法及装置。

[0006] 第一方面,本申请提供了一种基于机器学习的太赫兹物质识别方法。所述方法包括:

- 获取太赫兹光谱数据;
- 太赫兹光谱数据存入数据库;
- 数据预处理;
- 特征工程;
- 机器学习训练预测模型;
- 预测物质成分;
- 优化预测模型。

[0007] 第二方面,本申请还提供了一种基于机器学习的太赫兹物质识别装置。所述装置包括:

- 获取模块,用于获取太赫兹光谱数据;
- 存储模块,存储太赫兹光谱数据、机器学习相关数据;

数据处理模块,太赫兹光谱图像做图像去噪、图像倾斜校正、图像二值化、图像采样和图像量化,对太赫兹光谱数据采用小波变化、傅里叶变换等做数据转换,对光谱信息和测量相关数据(如检测物质相关信息、时间、温度和湿度等)机器学习的数据结构转换、数据类型转换、数据归一化、数据拆分为训练数据和测试数据;

机器学习训练模块,采用机器学习算法基于训练数据生成预测模型;

机器学习预测模块,采用预测模型对测试数据或待预测物质的太赫兹光谱数据进行预测;

机器学习评估模块,采用混淆矩阵或分类评估方法根据机器学习预测模型对测试数据的预测结果评估其预测水平;

统计分析模块,统计分析数据库中各类数据;

数据展示模块,提供数据展示功能,采用报表、投屏等方式展示数据。

[0008] 上述基于机器学习的太赫兹物质识别方法及装置,获取已知或未知物质的太赫兹光谱数据,在数据库中对光谱数据进行数据处理,根据已知物质的太赫兹光谱数据训练机器学习预测模型并评估预测水平,基于未知物质的太赫兹光谱数据采用符合预测水平的机器学习预测模型预测识别未知物质。

[0009] 相比于仅用太赫兹光谱特征值识别物质的方式,不但减少了信息损失,而且效率高。

附图说明

[0010] 图1为一个实施例中基于机器学习的太赫兹物质识别方法示意图;

图2为一个实施例中太赫兹光谱数值化示意图;

图3 为一个实施例中太赫兹光谱数据存储结构示意图;

图4为一个实施例中基于机器学习的太赫兹物质识别装置示意图。

具体实施方式

[0011] 为了便于理解本发明,下面将对本发明进行更全面的描述,本发明可以以许多不同的形式来实现,并不限于本文所描述的实施例。相反地,提供这些实施例的目的是使本发明公开内容更加透彻全面。

[0012] 除非另有定义,本文所使用的所有的技术和科学术语与属于本发明的技术领域的技术人员通常理解的含义相同。本文中在本发明的说明书中所使用的术语只是为了描述具体的实施例的目的,不是旨在于限制本发明。

[0013] 本申请提供了一种基于机器学习的太赫兹物质识别方法,如图1所示,所述方法包括以下步骤:

S101,获取太赫兹光谱数据,其中太赫兹光谱数据为太赫兹频域光谱、太赫兹时域光谱或者从太赫兹检测装置获取的数据;

S102,太赫兹光谱数据存入数据库,对太赫兹光谱数据按照图像、格式化数据、文本信息等类别分别存储到对应的数据库;

S103,数据预处理,对图像做图像去噪、图像倾斜矫正、图像取样、图像量化、图像二值化、图像矩阵表示后转为一维数组或数据库中一条记录方式,对强度、相位、折射率等

数据采用傅里叶变换或小波变换为吸收度、频率形式的数据；

S104,特征工程,选择特征列,选择目标列,对特征列数值做数据结构转换、数据类型转换和数据归一化,对目标列做数字化转换,机器学习数据按照一定比例拆分为训练数据和测试数据；

S105,机器学习训练预测模型,根据数据标注情况选择采用分类机器学习算法或聚类机器学习算法基于训练数据生成预测模型,采用预测模型对测试数据进行预测,评估预测模型对测试数据的预测水平；

S106,预测物质成分,把未知物质对应的太赫兹光谱数据采用预测模型进行预测,识别出未知物质；

S107,优化预测模型,对未知物质的预测结果错误的进行调整后和预测结果正确的数据一起纳入机器学习数据集,重新生成预测模型。

[0014] 进一步的,S101可进一步具体为：

S10101,获取已知物质成分的太赫兹频域光谱图像；

S10102,获取已知物质成分的太赫兹光谱描述数据；

S10103,获取已知物质成分的太赫兹检测数据；

S10104,获取未知物质成分的太赫兹频域光谱图像；

S10105,获取未知物质成分的太赫兹光谱描述数据；

S10106,获取未知物质成分的太赫兹检测数据。

[0015] 进一步的,S102可进一步具体为：

S10201,选择太赫兹光谱图像；

S10202,确定太赫兹图像唯一编码；

S10203,太赫兹光谱图像存入图像数据库,如对象存储、图数据库或存储图像位置信息等方式；

S10204,选择太赫兹光谱对应描述数据

S10205,太赫兹描述数据存入关系型数据库或Nosql数据库；

S10206,选择太赫兹检测数据；

S10207,确定太赫兹检测数据对应唯一编码；

S10208,太赫兹检测数据存入关系型数据库或NoSql数据库。

[0016] 进一步的,S103可进一步具体为：

S10301,太赫兹频域光谱图像；

S10302,太赫兹频域光谱图像去噪；

S10303,太赫兹频域光谱图像倾斜校正；

S10304,判断是否需要太赫兹频域光谱图像二值化；

S10305,太赫兹频域光谱图像二值化；

S10306,太赫兹频域光谱图像取样；

S10307,太赫兹频域光谱图像量化；

S10308,太赫兹频域光谱图像矩阵化表示；

S10309,太赫兹频域光谱图像转为一维数组或数据库中一条记录；

S10310,判断是否需要太赫兹图像描述数据转换；

S10311,根据预设规则把太赫兹图像描述数据通过傅立叶变换或小波变换等方法转换为统一的量纲;

S10312,判断是否需要太赫兹检测数据转换;

S10313,根据预设规则把太赫兹检测数据通过傅立叶变换或小波变换等方法转换为统一的量纲,例如把太赫兹检测数据的电场数据转化为频域数据;

S10314,太赫兹时域光谱图像;

S10315,太赫兹时域光谱图像去噪;

S10316,太赫兹时域光谱图像取样;

S10317,太赫兹时域光谱图像量化;

S10318,太赫兹时域光谱图像矩阵化表示;

S10319,太赫兹时域光谱图像转为一维数组或数据库中一条记录;

S10320,按照预设规则把时域光谱图像的一维数据通过傅立叶变换或小波变换等方法转化为统一的量纲。

[0017] 其中太赫兹频域光谱的取样和量化如图2所示,把连续的太赫兹频域光谱转换为离散的点,太赫兹频域光谱图像转为一维数组或数据库中一条记录如图3所示,可以采用数组、数据表、KV、Jason等方式存取。

[0018] 进一步的,步骤S104可进一步具体为:

S10401,选择全部或部分预处理后的数据作为特征列;

S10402,选择物质成分为目标列;

S10403,若采用二分类机器学习算法则某已知物质数值设为“1”,其他已知物质设为“0”;

S10404,若采用多分类机器学习算法则按照物质类别分别做数字编号;

S10405,若采用聚类机器学习算法则无需选择目标列;

S10406,对特征列数值做数据结构转化,例如转为大数据宽表形式;

S10407,对特征列数值做数据类型转化,例如统一转为Double类型;

S10408,对特征列数值做归一化处理,把数值压缩到[0,1]区间,去除量纲影响,加快收敛速度;

进一步的,S105可进一步具体为:

S10501,若存在一定量的特征值对应的为已知物质成分;

S10502,采用分类机器学习算法(如逻辑回归、支持向量机、随机森林、K近邻等)基于训练数据生成预测模型;

S10503,采用预测模型对测试数据预测,生成预测结果;

S10504,采用混淆矩阵或分类评估算法对预测结果评估;

S10505,若具备分类能力(预测结果概率大于0.5),则预测模型可用;

S10506,对未知物质成分的光谱数据采用预测模型预测;

S10507,若预测结果符合预设规则(如概率大于0.8),则未知物质属于训练数据中某已知物质成分类别;

S10508,若预测结果低于预设规则(如概率小于0.5),则未知物质不属于训练数据中所有物质成分中的一种;

S10509,采用聚类机器学习算法(如K-Means、DBSCAN等)对物质的光谱数据进行计算;

S10510,根据聚类情况判断物质的归属类别;

S10511,若分类或聚类算法均无法对未知物质成分进行识别;

S10512,则该物质成分为数据库中不存在的类别;

S10513,通过其他手段识别该物质成分,得到识别结果;

S10514,根据所述识别结果,在数据库中修改、补充相应信息。

[0019] 应该理解的是,虽然如上所述的各实施例所涉及的流程图中的各个步骤按照箭头的指示依次显示,但是这些步骤并不是必然按照箭头指示的顺序依次执行。除非本文中有明确的说明,这些步骤的执行并没有严格的顺序限制,这些步骤可以以其它的顺序执行。而且,如上所述的各实施例所涉及的流程图中的至少一部分步骤可以包括多个步骤或者多个阶段,这些步骤或者阶段并不必然是在同一时刻执行完成,而是可以在不同的时刻执行,这些步骤或者阶段的执行顺序也不必然是依次进行,而是可以与其它步骤或者其它步骤中的步骤或者阶段的至少一部分轮流或者交替地执行。

[0020] 基于同样的发明构思,本申请实施例还提供了一种用于实现上述所涉及的基于机器学习的太赫兹物质识别装置,如图4所示。所述装置包括:

获取模块401,用于获取太赫兹光谱数据;

存储模块402,存储太赫兹光谱数据、机器学习相关数据;

数据处理模块403,数据处理模块,太赫兹光谱图像做图像去噪、图像倾斜校正、图像二值化、图像采样和图像量化,对太赫兹光谱数据采用小波变化、傅里叶变换等做数据转换,对光谱信息和测量相关数据(如检测物质相关信息、时间、温度和湿度等)机器学习的数据结构转换、数据类型转换、数据归一化、数据拆分为训练数据和测试数据;

机器学习训练模块404,采用机器学习算法基于训练数据生成预测模型;

机器学习预测模块405,采用预测模型对测试数据或待预测物质的太赫兹光谱数据进行预测;

机器学习评估模块406,采用混淆矩阵或分类评估方法根据机器学习预测模型对测试数据的预测结果评估其预测水平;

统计分析模块407,统计分析数据库中各类数据;

数据展示模块408,提供数据展示功能,采用报表、投屏等方式展示数据。

[0021] 上述基于机器学习的太赫兹物质识别装置中的各个模块可全部或部分通过软件、硬件及其组合来实现。

[0022] 本文中所描述的具体实施例仅是对本发明精神的举例说明。本发明所属技术领域的技术人员可以对所描述的具体实施例做各种各样的修改或补充或采用类似的方式替代,但并不会偏离本发明的精神或者超越所附权利要求书所定义的范围。




图1




图2




图3




图4